

Pseudonymisation des données

Atelier professionnalisant



BTS SIO

La pratique de la pseudonymisation est le fait de remplacer toutes les données à caractères personnelles d'un jeu de données par d'autres données qui ne permettent pas l'identification directe (alias, code alphanumérique, etc). Cette pratique permet donc le traitement des données des individus sans pouvoir les identifier de façon directe. Il s'agit d'une opération réversible, il est donc possible de retrouver l'identité d'une personne à condition de connaître le processus de pseudonymisation.

Ce processus assure la sécurité des données tout en permettant une utilisation sans encombre. La pseudonymisation est utilisée dans le cadre d'un traitement de données à des fins de recherche scientifique lorsqu'il est nécessaire d'avoir des informations exactes au niveau individuel sans que les données permettant l'identification ne soient nécessaires pour mener cette recherche.

En pratique, il est possible de retrouver l'identité des personnes dont les données ont été pseudonymisées. Les données résultant d'une pseudonymisation sont donc considérées comme des données personnelles et leur traitement reste intégralement soumis aux obligations du RGPD. Le RGPD encourage tout de même l'utilisation. La pseudonymisation réduit en effet le risque de mise en corrélation d'un ensemble de données avec l'identité originale d'une personne concernée : il s'agit donc d'une mesure de sécurité utile contribuant à la mise en conformité au RGPD.

Le résultat de la pseudonymisation peut être indépendant de la valeur initiale. Il peut également être dérivé des valeurs originales d'un attribut ou d'un ensemble d'attributs (hachage). Le terme d'attribut fait référence à une variable issue du jeu de données de départ tel qu'un nom, un prénom, une adresse, etc.

Plusieurs techniques de pseudonymisation peuvent être utilisées. Certaines reposent sur la création de pseudonymes relativement basiques, d'autres s'appuient sur les techniques cryptographiques :

- **Compteur** : Il s'agit de substituer un nombre, défini par un compteur, à un attribut ou un ensemble d'attributs. Une valeur initiale doit être définie puis incrémentée. Il est essentiel que les valeurs produites par le compteur ne se répètent jamais, pour éviter toute ambiguïté et que deux enregistrements distincts ne soient jamais rattachés à un même pseudonyme.

Pseudonymisation par utilisation d'un compteur

PRÉNOM	NOM	DATE DE NAISSANCE	PSEUDONYME
Nicolas	Durand	06/01/1978	113
Isabelle	Martin	25/05/1988	114
Marie-Noëlle	Dupond	03/02/1957	115
Karl	Petit	19/07/1965	116

- Générateur de nombres aléatoires : Il s'agit de produire des valeurs ayant une probabilité égale d'être sélectionnées au sein de la population totale de possibilités. Cette technique permet de créer des pseudonymes aléatoires, c'est-à-dire produisant des valeurs imprévisibles et indépendantes du jeu de données à caractère personnel initial.

Pseudonymisation par utilisation d'un générateur de nombres aléatoires

PRÉNOM	NOM	DATE DE NAISSANCE	PSEUDONYME
Nicolas	Durand	06/01/1978	75721
Isabelle	Martin	25/05/1988	865
Marie-Noëlle	Dupond	03/02/1957	42088
Karl	Petit	19/07/1965	2562

- Chiffrement à clé secrète : Il s'agit de chiffrer les données directement identifiantes pour les rendre incompréhensibles. Dans ce cas, le détenteur de la clé secrète peut identifier chaque personne concernée en déchiffrant l'ensemble de données, puisque les données personnelles y figurent toujours, bien que sous une forme chiffrée. Cette clé doit donc être conservée de façon sécurisée et accessible uniquement par les personnes autorisées. Par ailleurs, il est indispensable d'appliquer une méthode de chiffrement conforme à l'état de l'art.

Pseudonymisation par utilisation d'un chiffrement à clé secrète (ici AES avec clé de 256 bits :
DNSi_qED_P)f6;23nL7%5@y;cn,v7H47)

PRÉNOM	NOM	DATE DE NAISSANCE	PSEUDONYME
Nicolas	Durand	06/01/1978	e29843178f52fb57798627 48f06f2022b3c7c920a369 28eac6c25cbd7e562185
Isabelle	Martin	25/05/1988	806e37f131008057776fad 53ea1fb72d479e7e0e4435 539d03595a0ec5e2c435
Marie-Noëlle	Dupond	03/02/1957	55912722ffa374bce6320e 16acc2151a947ac1d118b3 20894d556fc43763140b
Karl	Petit	19/07/1965	5f9c846b57f88d55eaf97ad 900148239c00ce7cd1a566 6c3687a5ddd9d51fcd6

- Fonction de hachage : Il s'agit d'une fonction qui renvoie un résultat de taille fixe, quelle que soit la taille de l'entrée encodée et qui n'est pas conçue pour être inversée. Il n'est donc plus possible de récupérer facilement les données en clair, comme dans le cas du chiffrement.

Pseudonymisation par utilisation d'une fonction de hachage (ici Scrypt avec sel de 256 bits : Yv2uZ/i+F7/f5(hZiW7i[6V@4s5*G4=G)

PRÉNOM	NOM	DATE DE NAISSANCE	PSEUDONYME
Nicolas	Durand	06/01/1978	eeff86b4a738a90c0dfaa71ac8a3dd8cef5ba6f3eff8b9edf5f6af73a1abdddc
Isabelle	Martin	25/05/1988	906cfc57fdc8e489f4383a93cbc9b824555aafe275a627dfe55521f46d69c531
Marie-Noëlle	Dupond	03/02/1957	ab9ef82e90636a9ba351ec589905656bde12a6b63c1b57c82364b628d911cc27
Karl	Petit	19/07/1965	c7212903e6c1807d34be14d25975e9b902f47dc278985a75cb6ac986f1461f54

Il est nécessaire de se concentrer sur la faisabilité et pertinence de chaque technique, il est alors possible de réaliser les commentaires suivants :

- Compteur : Solution à éviter dans le cas de jeux de données de grande taille (ce qui sera le cas pour des études de santé centralisées sur tout le territoire) ;
- Générateur de nombres aléatoires : Solution à éviter également (risque de redondance de pseudonyme en cas d'absence de vigilance) ;
- Chiffrement à clé secrète : Solution intéressante pour la sécurité des données, seules les personnes autorisées peuvent déchiffrer les informations ;
- Fonction de hachage : Solution intéressante mais à éviter, impossible de retrouver les données d'origine. Cette méthode est sensible aux attaques par force brute. Souvent à associer à la fonction "salage" qui ajoute une part d'aléatoire dans le résultat.

En conclusion, la technique de pseudonymisation la plus intéressante dans le contexte de la clinique Pasteur est le chiffrement à clé secrète. En effet, ce chiffrement permet d'assurer la confidentialité des données en empêchant quiconque ne possédant pas la clé secrète d'accéder aux données. De plus, le chiffrement permet un retour en arrière, c'est-à-dire, l'accès aux données essentielles pour mener à bien les études.

Pour la mise en place du chiffrement des données en python, nous utiliserons la bibliothèque cryptography dont il s'agit de la fonction première.

Voici un lien explicatif pour savoir comment le mettre en place : <https://fr.itrip.xyz/python/python-cryptography-basics>